FluxProp: Deep Liquid Neural Networks with Spatial Residuals and Low-Rank Markovian Routing

Independent Researcher

2026 年 4 月 15 日

摘要

虽然液态神经网络 (LNNs) 展现出了出色的连续时间动力学特性，但其深层空间堆叠往往容易受到梯度消失的影响。本文正式提出了 FluxProp 框架。我们对随时间反向传播 (BPTT) 进行了严谨的空间-时间联合雅可比分析，并引入了空间残差机制，旨在缓解深层结构中的梯度衰减。此外，为了在不产生 $\mathcal{O}(d^2)$ 计算开销的情况下解决特征饱和问题，我们提出了低秩前向马尔可夫路由机制。我们提供了详细的数学推导，证明该前向操作通过自动微分 (Autograd) 自然产生受马尔可夫约束的反向梯度，从而在理论上降低了对启发式 Backward Hooks 的依赖。

1 时间动力学离散化 (Temporal Dynamics Discretization)

LNN 的核心是一个连续时间动力系统。对于给定的层 l，隐藏状态向量 $\boldsymbol{h}^{(l)}(t) \in \mathbb{R}^d$ 随时间 t 的演化由非线性常微分方程 (ODE) 支配：

$$\frac{\mathrm{d}\boldsymbol{h}^{(l)}(t)}{\mathrm{d}t} = -\boldsymbol{\alpha} \odot \boldsymbol{h}^{(l)}(t) + f\left(\boldsymbol{W}^{(l)}\boldsymbol{h}^{(l)}(t) + \boldsymbol{U}^{(l)}\boldsymbol{x}^{(l)}(t) + \boldsymbol{b}^{(l)}\right) \tag{1}$$

其中 $\boldsymbol{\alpha} \in (0,1)^d$ 为通道级独立的时间衰减常数向量（在代码实现中，为保证耗散系统的绝对稳定性，使用无界参数 $\boldsymbol{\alpha}_{\text{raw}}$ 经逻辑函数约束得到 $\boldsymbol{\alpha} = \sigma(\boldsymbol{\alpha}_{\text{raw}})$），$f$ 为非线性激活函数（如 tanh），$\boldsymbol{x}^{(l)}(t)$ 为输入通量，$\odot$ 为哈达玛积 (Hadamard product)。

对于离散序列处理，我们采用步长 $\Delta t = 1$ 的前向欧拉法。令 $\boldsymbol{h}_t^{(l)}$ 表示 l 层在离散时间步 t 的状态，离散更新方程严格对应于代码中的液态刺激计算：

$$\boldsymbol{h}_t^{(l)} = (\boldsymbol{1} - \boldsymbol{\alpha}) \odot \boldsymbol{h}_{t-1}^{(l)} + f\left(\boldsymbol{W}^{(l)}\boldsymbol{h}_{t-1}^{(l)} + \boldsymbol{U}^{(l)}\boldsymbol{x}_t^{(l)} + \boldsymbol{b}^{(l)}\right) \tag{2}$$

2 空间-时间联合雅可比分析 (Joint Jacobian Analysis)

在不带残差的深层堆叠架构中，第 l 层的输入为 $\boldsymbol{x}_t^{(l)} = \boldsymbol{h}_t^{(l-1)}$。在 BPTT 过程中，梯度沿时间与空间两个维度流动。其动力学由两个雅可比矩阵决定：

1. 时间雅可比 (Time Flow):

$$\boldsymbol{J}_{\text{time}}^{(l)} = \frac{\partial \boldsymbol{h}_t^{(l)}}{\partial \boldsymbol{h}_{t-1}^{(l)}} = \text{diag}(\mathbf{1} - \boldsymbol{\alpha}) + \text{diag}\left(f'(\cdot)\right) \boldsymbol{W}^{(l)} \tag{3}$$

主对角项 $\text{diag}(\mathbf{1} - \boldsymbol{\alpha})$ 在时间维度上充当了一条长期的自回归留存通道，有效避免了连乘导致的谱范数弥散。

2. 空间雅可比 (Depth Flow):

$$\boldsymbol{J}_{\text{space}}^{(l)} = \frac{\partial \boldsymbol{h}_t^{(l)}}{\partial \boldsymbol{x}_t^{(l)}} = \text{diag}\left(f'(\cdot)\right) \boldsymbol{U}^{(l)} \tag{4}$$

对于深度为 L 的网络，从顶层回传至底层输入的空间梯度需要通过链式法则进行连乘：

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{x}_t^{(1)}} = \left(\prod_{l=1}^{L} \frac{\partial \boldsymbol{h}_t^{(l)}}{\partial \boldsymbol{x}_t^{(l)}}\right) \frac{\partial \mathcal{L}}{\partial \boldsymbol{h}_t^{(L)}} = \left(\prod_{l=1}^{L} \boldsymbol{J}_{\text{space}}^{(l)}\right) \frac{\partial \mathcal{L}}{\partial \boldsymbol{h}_t^{(L)}} \tag{5}$$

由于 $\|f'(\cdot)\| \leq 1$，算子 $\prod \boldsymbol{J}_{\text{space}}^{(l)}$ 的奇异值随深度呈指数级衰减。

空间残差修正 (ReZero): 我们显式地在空间维度引入由可学习标量缩放因子 γ 控制的恒等残差映射：

$$\boldsymbol{y}_t^{(l)} = \gamma \tilde{\boldsymbol{h}}_t^{(l)} + \text{Proj}(\boldsymbol{x}_t^{(l)}) \tag{6}$$

此时，新的空间雅可比变为 $\frac{\partial \boldsymbol{y}_t^{(l)}}{\partial \boldsymbol{x}_t^{(l)}} = \gamma \frac{\partial \tilde{\boldsymbol{h}}_t^{(l)}}{\partial \boldsymbol{x}_t^{(l)}} + \boldsymbol{W}_{\text{Proj}}$。根据代码策略，我们在初始化时强制令 $\gamma = 0$。此时当空间维数一致时 $\boldsymbol{W}_{\text{Proj}} = \boldsymbol{I}$，恒等矩阵的存在使得初始稳态下的跨深度空间连乘雅可比严格等于单位阵 $\boldsymbol{I}$。这在数学上为跨深度的梯度流动提供了“高速公路”，为逐层解冻的课程训练策略提供了合法性支撑。

3 低秩马尔可夫状态路由 (LSR)

为了避免在高维空间直接构建 $\mathcal{O}(d^2)$ 的马尔可夫矩阵，我们将状态映射到低维瓶颈子空间 $r \ll d$：

$$\boldsymbol{q}_t = \boldsymbol{W}_Q \boldsymbol{h}_t, \quad \boldsymbol{k}_t = \boldsymbol{W}_K \boldsymbol{h}_t, \quad \boldsymbol{v}_t = \boldsymbol{W}_V \boldsymbol{h}_t \quad \in \mathbb{R}^r \tag{7}$$

利用缩放点积形式构造低秩转移概率矩阵 $\boldsymbol{M}_t \in \mathbb{R}^{r \times r}$：

$$\boldsymbol{M}_t = \text{Softmax}\left(\frac{\boldsymbol{q}_t \boldsymbol{k}_t^\top}{\sqrt{r}}, \text{dim} = -1\right) \tag{8}$$

列归一化使得 $\boldsymbol{M}_t$ 严格满足右随机矩阵的性质。随后通过通量路由并重新升维投影回 d 维主空间：

$$\tilde{\boldsymbol{h}}_t = \boldsymbol{W}_O (\boldsymbol{M}_t \boldsymbol{v}_t) \tag{9}$$

该机制将计算与显存复杂度从严酷的 $\mathcal{O}(d^2)$ 降低至 $\mathcal{O}(dr + r^2)$。

4 定理 1：马尔可夫梯度的自发涌现 (Emergent Gradients)

我们在此用张量微积分严格证明：前向过程中的路由操作会引导自动微分引擎自然产生符合马尔可夫权重的梯度流。

定理 1. *前向传播中的低秩马尔可夫路由操作 $\tilde{\boldsymbol{h}}_t = \boldsymbol{W}_O(\boldsymbol{M}_t\boldsymbol{v}_t)$，会在反向传播（BPTT）时自发涌现出受马尔可夫概率转移矩阵的转置 $\boldsymbol{M}_t^\top$ 精确加权主导的梯度流。*

证明. 令上游回传流入该层的误差梯度向量为 $\boldsymbol{g} = \nabla_{\tilde{\boldsymbol{h}}_t}\mathcal{L} \in \mathbb{R}^d$。隐状态 $\boldsymbol{h}_t$ 的全导数由通量物理漂移路径与概率动态重塑路径共同构成。

首先，回流至低秩瓶颈的梯度为 $\boldsymbol{g}_v = \nabla_{\tilde{\boldsymbol{v}}_t}\mathcal{L} = \boldsymbol{W}_O^\top\boldsymbol{g} \in \mathbb{R}^r$。

考虑主导项：**通量物理漂移 (Flux Drift)**。假定转移概率矩阵 $\boldsymbol{M}_t$ 暂时为静态常量。由路由分发操作 $\tilde{v}_{t,i} = \sum_{j=1}^r M_{t,ij}v_{t,j}$，标量损失 $\mathcal{L}$ 对通量 $\boldsymbol{v}_t$ 的第 k 个元素的偏导为：

$$\frac{\partial\mathcal{L}}{\partial v_{t,k}} = \sum_{i=1}^r \frac{\partial\mathcal{L}}{\partial\tilde{v}_{t,i}}\frac{\partial\tilde{v}_{t,i}}{\partial v_{t,k}} = \sum_{i=1}^r(\boldsymbol{g}_v)_i\frac{\partial}{\partial v_{t,k}}\left(\sum_{j=1}^r M_{t,ij}v_{t,j}\right) \tag{10}$$

利用克罗内克符号 $\frac{\partial v_{t,j}}{\partial v_{t,k}} = \delta_{jk}$，上式即化简为 $\sum_{i=1}^r(\boldsymbol{g}_v)_i M_{t,ik}$。将其还原为全局向量-矩阵乘积形式即为：

$$\nabla_{\boldsymbol{v}_t}\mathcal{L} = \boldsymbol{M}_t^\top\boldsymbol{g}_v = \boldsymbol{M}_t^\top\boldsymbol{W}_O^\top\boldsymbol{g} \tag{11}$$

又因 $\boldsymbol{v}_t = \boldsymbol{W}_V\boldsymbol{h}_t$，该支路反向传至 $\boldsymbol{h}_t$ 的梯度贡献为主导项 Term A：

$$\text{Term A} = \boldsymbol{W}_V^\top\boldsymbol{M}_t^\top\boldsymbol{W}_O^\top(\nabla_{\tilde{\boldsymbol{h}}_t}\mathcal{L}) \tag{12}$$

其次，考虑 **概率动态重塑**路径。隐状态的微小变化导致 $\boldsymbol{q}_t, \boldsymbol{k}_t$ 改变，从而重塑了 $\boldsymbol{M}_t$ 的流形分布。利用 Softmax 的雅可比性质 $\frac{\partial M_{ij}}{\partial Z_{im}} = M_{ij}(\delta_{jm} - M_{im})$，这反映了隐藏状态对转移权重本身的二阶调节作用，可紧凑记为修正项 Term B：

$$\text{Term B} = \boldsymbol{J}_{\text{Softmax}}(\boldsymbol{h}_t)^\top(\nabla_{\tilde{\boldsymbol{h}}_t}\mathcal{L}) \tag{13}$$

合并两条路径，得出隐状态的完整封闭解析梯度：

$$\frac{\partial\mathcal{L}}{\partial\boldsymbol{h}_t} = \underbrace{\boldsymbol{W}_V^\top\boldsymbol{M}_t^\top\boldsymbol{W}_O^\top(\nabla_{\tilde{\boldsymbol{h}}_t}\mathcal{L})}_{\text{主导项: 马尔可夫转置加权}} + \underbrace{\boldsymbol{J}_{\text{Softmax}}(\boldsymbol{h}_t)^\top(\nabla_{\tilde{\boldsymbol{h}}_t}\mathcal{L})}_{\text{调节项: 概率流形二阶重塑}} \tag{14}$$

主导项中 $\boldsymbol{M}_t^\top$ 的涌现，展现了系统惊人的动力学对偶性 (Duality)：前向传递按流形概率拓扑分配信息，反向传播时误差信号会自动且精准地按照 ** 相反方向（概率转置）** 倒灌。这就使得模型无需手动反向 Hook 即可自发完成信用分配。 □

5 FluxProp 完整计算架构

综合以上推导，单层 FluxProp 在时间步 t 的完整前向计算图如下（其在数学上完美等效于给定的 PyTorch 实现代码）：

$$\boldsymbol{h}_t = (\mathbf{1} - \sigma(\boldsymbol{\alpha}_{\text{raw}})) \odot \boldsymbol{h}_{t-1} + \tanh\left(\boldsymbol{W}^{(l)}\boldsymbol{h}_{t-1} + \boldsymbol{U}^{(l)}\boldsymbol{x}_t + \boldsymbol{b}^{(l)}\right) \tag{15}$$

$$\boldsymbol{q}_t = \boldsymbol{W}_Q\boldsymbol{h}_t, \quad \boldsymbol{k}_t = \boldsymbol{W}_K\boldsymbol{h}_t, \quad \boldsymbol{v}_t = \boldsymbol{W}_V\boldsymbol{h}_t \tag{16}$$

$$\boldsymbol{M}_t = \text{Softmax}\left(\frac{\boldsymbol{q}_t\boldsymbol{k}_t^\top}{\sqrt{r}}, \text{dim} = -1\right) \tag{17}$$

$$\tilde{\boldsymbol{h}}_t = \boldsymbol{W}_O(\boldsymbol{M}_t\boldsymbol{v}_t) \tag{18}$$

$$\boldsymbol{y}_t = \gamma\tilde{\boldsymbol{h}}_t + \text{Proj}(\boldsymbol{x}_t) \tag{19}$$